

Dokumentacja wstępna

- Mikołaj Garbowski
- Maksym Bieńkowski

Opis zadania

Chcemy zbadać algorytm minimalizowania przewidywalności opisany w artykule [1] do zastosowań w zakresie mechanistycznej interpretowalności, jako alternatywę do wykorzystania modeli typu SAE [2].

Algorytm [1] służy do wyznaczania reprezentacji wektora liczb rzeczywistych przez adversarialny trening modułów wyznaczających reprezentację oraz modułów przewidujących pojedynczy element reprezentacji na podstawie pozostałych elementów. Takie zadanie optymalizacji prowadzi do reprezentacji, w której wszystkie elementy są wzajemnie niezależne.

Algorytm można rozumieć jako nienadzorowane uczenie się słownika reprezentacji. Oczekujemy że w wyniku treningu otrzymamy słownik, w którym każdy element odpowiada pojedynczemu (monosemantycznemu) konceptowi, interpretowalnemu przez człowieka.

Planujemy wytrenować opisany model na aktywacjach modelu generatywnego StableDiffusion 1.4 w celu dekompozycji aktywacji, gdzie w ogólności pojedyncze neurony są polisemantyczne, w celu:

1. Możliwości zinterpretowania tych aktywacji
2. Możliwości wykonania interwencji, w celu wzmocnienia/osłabienia wybranego konceptu w generowanej próbce (obrazie)

Jako punkt odniesienia do naszych badań wykorzystamy [3], gdzie autorzy zidentyfikowali interesujące warstwy w modelu StableDiffusion 1.4 za pomocą rzadkiego autokodera.

Architektura modelu

Dla rozmiaru słownika n , model składa się z:

- n modułów f_i wyznaczających reprezentację
 - w szczególności perceptron wielowarstwowy z jednym neuronem w warstwie wyjściowej
- n predyktorów g_i
 - w szczególności perceptron wielowarstwowy z jednym neuronem w warstwie wyjściowej
 - $g_i : \mathbb{R}^{n-1} \rightarrow \mathbb{R}$
 - wejście to wszystkie pozycje reprezentacji poza i
 - wyjście to predykcja pozycji i reprezentacji
- opcjonalny moduł dekodera
 - wtedy model ma ogólną strukturę autokodera

- istotny jeśli chcemy przenieść interwencję w przestrzeni słownika na przestrzeń aktywacji modelu generatywnego

Zaimplementowany wariant modelu

Implementacja predyktorów jako oddzielnej sieci neuronowej (MLP) dla każdego elementu reprezentacji prowadzi do ogromnej liczby parametrów. Zdecydowaliśmy się na bardziej kompaktowy wariant z jednym współdzielonym predyktorem. Współdzielony predyktor jest perceptronem wielowarstwowym. Jego wejście stanowi n -wymiarowy wektor reprezentacji, w którym i -ty element jest wyzerowany oraz wektor zanurzenia indeksu i -tego elementu reprezentacji. W ten sposób predyktor może rozróżnić który element reprezentacji ma przewidywać, a jednocześnie liczba parametrów jest liniowa względem rozmiaru słownika.

Koder i dekodek są pojedynczymi warstwami liniowymi.

Trening odbywa się w naprzemiennych fazach:

1. Trening predyktora
 - Minimalizuje błąd predykcji reprezentacji (MSE)
 - Równoważne maksymalizacji przewidywalności reprezentacji (każdego elementu na podstawie pozostałych)
2. Trening autokodera
 - Minimalizuje błąd rekonstrukcji i minimalizuje przewidywalność reprezentacji (strata predyktora z odwróconym znakiem)
 - Funkcja straty to suma ważona tych dwóch składników, waga jest hiperparametrem

Fazy zmieniają się co określoną liczbę minipakietów, liczba jest hiperparametrem.

Zrealizowane kroki


- Zbieranie aktywacji z warstw modelu StableDiffusion 1.4 dla promptów ze zbioru danych COCO.
 - Zapisane w zbiorze danych dostępnym na HuggingFace
- Implementacja i trening modelu minimalizowania przewidywalności.
 - Wagi wytrenowanych modeli zapisane na platformie Weights and Biases
- Implementacja metody interwencji w generacji obrazka
 - Interwencja polega na przepuszczeniu aktywacji przez koder, zmianie wybranych wymiarów reprezentacji, przepuszczeniu zmienionej reprezentacji przez dekodek i wprowadzeniu zmienionych aktywacji z powrotem do modelu generatywnego.
 - Zaimplementowana metoda pozwala na wzmocnienie lub osłabienie wybranego konceptu poprzez przemnożenie wybranych wymiarów przez skalar.

- Demonstracja metody interwencji jest przedstawiona w notatniku 04-intervention-demo
- Wizualizacja aktywacji poszczególnych wymiarów słownika w postaci heat-map
 - demonstracja API w notatniku
- Analiza przestrzeni słownika pod kątem istotności wymiarów reprezentacji dla danych konceptów
 - wymiarom przestrzeni ukrytej słownika jest przypisywana miara istotności dla wybranego konceptu
 - w celu interwencji wybieramy wymiary o najwyższej istotności i skalujemy je uwzględniając ich średnią aktywację w zbiorze danych oraz siłę interwencji (parametr)

Przykładowe działanie interwencji

Obrazki otrzymane w wyniku przeskalowania najistotniejszych wymiarów słownika dla danego stylu z siłą odpowiednio w kolejnych wierszach:

- oryginalny obrazek (bez użycia autokodera)
- 1
- 0
- -1
- -10



Rysunek 1: Demonstracja obrazków otrzymanych w wyniku interwencji

Przykładowa wizualizacja aktywacji wymiaru słownika



Rysunek 2: Przykładowa wizualizacja istotności wymiaru słownika

Bibliografia

- [1] J. Schmidhuber, „Learning Factorial Codes by Predictability Minimization”, *Neural Computation*, t. 4, nr 6, s. 863–879, 1992, doi: 10.1162/neco.1992.4.6.863.
- [2] B. A. Olshausen i D. J. Field, „Sparse Coding with an Overcomplete Basis Set: A Strategy Employed by V1?”, *Vision Research*, t. 37, nr 23, s. 3311–3325, grudz. 1997, doi: 10.1016/S0042-6989(97)00169-7.
- [3] B. Cywiński i K. Deja, „SAeUron: Interpretable Concept Unlearning in Diffusion Models with Sparse Autoencoders”, w *Forty-second International Conference on Machine Learning*, 2025. Dostępne na: <https://arxiv.org/abs/2501.18052>